

# **Problemas Multimodais e Distribuição Espacial**

Capítulo 9



# Roteiro

- Introdução
  - Motivação;
  - Problemas multimodais;
- Abordagens implícitas para manutenção de diversidade.
- Abordagens explícitas para manutenção de diversidade.
- Algoritmos evolucionários multiobjetivos:
  - Problemas de otimização multiobjetivos.
  - Otimização multiobjetivo por pareto e dominância.
  - Otimização multiobjetivo com EAs.
- Exemplo e resumo.

# Introdução

- No processo natural, influenciam a evolução das espécies:
  - A aptidão de cada indivíduo.
  - Outros fatores, como o espaço físico onde ocorre a evolução, impõem o conceito de localidade.
- São exemplos destes processos os jardins que são semeados por polens de outras localidades e, até mesmo, o surgimento da vida na Terra (supostamente semeada por materiais extraterrestres, advindos de asteróides e cometas).

# Introdução


- Separação de espécies pode ajudar na manutenção de diversidade em uma população.
- Diferentes subgrupos de uma mesma população global podem se adaptar levando em conta suas condições locais.
- Há teoria afirmando que a evolução das espécies é entendida como um resultado final do crescimento de adaptações especializadas de nichos particulares.

# Introdução

- A divisão de uma população global em grupos de subpopulações de comunicação pouco freqüente, seguindo restrições de acasalamento durante a evolução das espécies, objetiva preservar a diversidade e ajudar na busca de soluções de alta qualidade em problemas multimodais.
- As subpopulações sugerem o uso de computação evolucionária em duas áreas: otimização multiobjetivo e problemas dinâmicos.

# Motivação 1: Problemas Multimodais

- Problemas caracterizados pela existência de várias soluções ótimas restritas a uma vizinhança mas com aptidão inferior a da solução ótima global.



# Motivação 1: Problemas Multimodais

- O espaço de busca pode ser dividido em “bacias atratoras” em torno de ótimos locais:
  - Um ótimo local é um ponto para onde algoritmos de busca local convergem.
- Estas bacias usualmente possuem diferentes tamanhos e perfis.
- Nicho é o termo atribuído a estas regiões disjuntas de aptidão alta.

# Motivação 1: Problemas Multimodais

- Os Algoritmos Evolucionários (AEs) são adequados para este tipo de problemas por ser capaz de:
  - Encontrar o ótimo global devido às buscas múltiplas.
  - Encontrar várias soluções de aptidão alta que correspondem aos ótimos locais. Usualmente, eles são necessários para casos em que a aptidão não especifica acuradamente o problema que a fundamenta.



## Motivação 2: Deriva Genética

- O deriva genética (*genetic drift*) ocorre em populações finitas quando os cruzamentos (*xover*) entre quaisquer indivíduos (*global* ou *panmictic mixing*) convergem para um único ótimo.
- A tendência inicial de convergir para um nicho é usualmente acentuada durante a evolução.
- Encontrar vários nichos pode ajudar na otimização quando um ótimo local possui a maior bacia atratora.

## Motivação 3: Biológica

- Evolução das Espécies:
  - Definição: Diferentes espécies adaptam-se para ocupar diferentes nichos ambientais, que possuem recursos finitos e indivíduos que competem entre si.
  - Restrição de cruzamento: Indivíduos se reproduzem apenas com outros da mesma espécie.
  - Exploração evolucionária tende a se restringir a um nicho aumentando possibilidade de homogeneidade de fenótipos dentro das espécies.

## Motivação 4: Equilíbrio Intercalado

- Equilíbrio Intercalado (*Punctuated Equilibrium*): Períodos de estabilidade que são interrompidos por rápido crescimento quando a população principal é “invadida” por indivíduos de grupos espacialmente isolados (*demes*) de uma mesma espécie.
  - A população principal é espacialmente dividida em sub-populações com migrações entre seus indivíduos.
- Adaptação Local:
  - Sub-populações isoladas apresentam adaptações locais em resposta a leves mudanças em seus ambientes. Por exemplo, animais ou pássaros com diferenças em hábitos alimentares, forma da boca e do bico, em resposta à disponibilidade local de alimentos.

# EAs para Problemas Multimodais

- As motivações descritas favoreceram a criação de mecanismos para emprego de EAs em problemas multimodais. Estes EAs visam manter a diversidade a partir de duas maneiras:
  - Abordagem implícita: Um arcabouço permite e induz a preservação de soluções diversas, embora não garanta sua ocorrência.
    - Considera separação geográfica ou evolução por espécies.
  - Abordagem explícita: Os operadores são modificados para preservar diversidade.
    - Força que indivíduos similares compitam por alimentos ou por sobrevivência com os demais.

# Espaços de Operação dos EAs


- Espaço Algorítmico:
  - Diferentes formas de estruturação e comunicação podem ser propostas (e.g., computação paralela).
  - Equivalente ao espaço geográfico de evolução.
- Espaço de Genótipos:
  - Métricas de distâncias para algum operador definem a estrutura de vizinhança sobre o conjunto de soluções representáveis.
- Espaço de Fenótipos:
  - Estrutura de vizinhança é baseada nas distâncias métricas entre soluções.

## Medidas Implícitas para Manter Diversidade

- Opções para achar um conjunto diverso de soluções para um problema multimodal:
  - Executar um AE padrão várias vezes e salvar boas soluções.
  - Executar vários AEs do tipo padrão ao mesmo tempo, permitindo o compartilhamento periódico de informações através de migração de indivíduos.
  - Introduzir a idéia de distribuição espacial numa única população através de operadores locais de seleção.
  - Manter diferentes espécies dentro de uma população única, tipificando-as e restringindo recombinações a indivíduos de mesma espécie.

## Medidas Implícitas: EAs de Modelo de Ilhas

Também chamada de EAs paralelos, EAs paralelos de granulação grosseira (*coarse-grain*).



## Medidas Implícitas: EAs de Modelo de Ilhas

- Procedimento:
  - Evoluir ilhas com múltiplas populações em paralelo, que possuam estrutura para comunicação entre si, usualmente um anel ou um toro.
  - Mover indivíduos para vizinhança (migração) após um número de gerações, normalmente pré-fixado.
  - Repetir até atingir um critério de parada.
- Emprega-se diferentes parâmetros para induzir ocorrência de diversidade: frequência de trocas, escolha de indivíduos a migrarem e número de subpopulações.



## Medidas Implícitas: EAs de Modelo de Ilhas


- Freqüência de Troca de Indivíduos:
  - Rápida: Convergência de populações para mesma solução.
  - Lenta: Esforço computacional perdido com populações que já convergiram.
  - Indicação da maioria do autores -> ~ 25-150 gerações.
  - Troca adaptativa. Por exemplo, interromper evolução em subpopulações sem melhoria na aptidão por um número de gerações (tipicamente, 25 gerações).

## Medidas Implícitas: EAs de Modelo de Ilhas

- Quantidade e Escolha de Indivíduos para Migrar:
  - Tipicamente, escolhe-se 2-5, contudo depende do tamanho da população.
  - Seleção para migrar baseada aptidão ou aleatória (esta parece ser a melhor).
  - Reposição de indivíduos (aleatória ou piores).
- Divisão da população em subpopulações
  - Número alto de subpopulações deve produzir resultados melhores que número baixo pois tende a considerar exploração de diferentes picos.

## Medidas Implícitas: EAs de Modelo de Difusão

- Também chamada EAs paralelos com granulação fina, EAs distribuídos ou EAs celulares.
- Estrutura espacial (em geral *grid*) em uma população, subdividida em subpopulações sobrepostas.



● Indivíduo  
atual

○ Vizinhos

## Medidas Implícitas: EAs de Modelo de Difusão

- Cada indivíduo existe num ponto de um *grid*.
- Seleção e aplicação de operadores só ocorrem entre vizinhos.
- Algoritmos desta abordagem se caracterizam por:
  - Distribuição da população em uma grade: um indivíduo por nó.
  - Existência de vizinhança (*deme*) para cada indivíduo.
  - Escolha de um *deme* por geração para ser operado.

## Medidas Implícitas: EAs de Modelo de Difusão

- Exemplo: Considere um *grid* retangular no qual cada indivíduo tem 8 vizinhos. As operações realizadas em cada *deme* são:
  - Escolha aleatoriamente um ponto da população.
  - Escolha um de seus vizinhos empregando a roleta.
  - Gere uma prole por recombinação e mute-a.
  - Substitua o indivíduo escolhido pela prole se esta for mais apta.
  - Repita na população até critério de parada.

## **Medidas Implícitas: Operações Automáticas na mesma Espécie (*Automatic Speciation*)**

- Recombinação em uma mesma espécie:
  - Indivíduos com genótipo/fenótipo similares.
  - Indivíduos com adição de bits identificadores de espécies.
- Os bits adicionados se caracterizam por:
  - Escolhidos aleatoriamente.
  - Sujeitos a recombinação e mutação.
  - Discriminantes de parceiros para recombinação.
  - Pode-se também empregar *tags* para realizar compartilhamento de aptidão para distribuir membros entre os nichos.

## Medidas Explícitas

- São baseados na idéia de se forçar a população para manter diferentes nichos ao se fazer a seleção ou reposição
- Maneiras: Compartilhamento de aptidão (*fitness sharing*) e aglomeração (*crowding*).
- Em ambos os casos, a escolha dos pais é global.

## Medida Explícita: Compartilhamento de Aptidão

- Restringe-se o número de indivíduos de um dado nicho através do “compartilhamento” de sua aptidão:
  - Aloca-se indivíduos para nichos proporcionalmente a aptidão do nicho.
- Necessita-se definir o tamanho do nicho  $\sigma_{\text{share}}$ .
- Executa AE normalmente mas antes de cada seleção re-define-se a aptidão para o indivíduo  $i$ :

$$f'(i) = \frac{f(i)}{\sum_{j=1}^m sh(d(i, j))}$$

$$sh(d) = \begin{cases} 1 - (d/s)^a & d \leq s \\ 0 & \text{de outro modo} \end{cases}$$




## Medida Explícita: Aglomeração

- Tenta distribuir os indivíduos uniformemente entre os nichos.
- Pré-supões que a prole tenderá a ser próxima aos pais.
- Emprega a métrica de distância no espaço **f/g**enótipo.
- 2 torneios pais/proles – escolhe sobreviventes levando em conta similaridades entre pais e filhos.

## Medida Explícita: Aglomeração

- Algoritmos da aglomeração determinística:
  - Forme pares de pais aleatoriamente escolhidos na população.
  - Produza duas proles a partir de cada par de pais.
  - Mute a prole e avalie sua aptidão.
  - Calcule as quatro distâncias entre cada pai e cada prole.
  - Selecione sobreviventes por torneio de modo a escolher a menor distância somada:
$$d(p1,o1)+d(p2,o2) < d(p1,o2) + d(p2,o1)$$

## ***Compartilhamento de Aptidão vs. Aglomeração***



Compartilhamento de aptidão aloca indivíduos aos picos proporcionalmente à aptidão enquanto aglomeração os distribui uniformemente.

## Problemas Multiobjetivo (PMOs)

- Problemas multimodais normalmente são multiobjetivos e se caracterizam pela presença de  $n$  objetivos, ao menos alguns deles, conflitantes entre si.
  - Exemplos: compra de um carro (preço X confiabilidade) e solução de engenharia (custo reduzido X segurança).
- Principais objetivos:
  - Encontrar solução que satisfaça todos os objetivos.
  - Priorizar um determinado objetivo (como ponderar?).
- Problema usualmente tratado em duas etapas:
  - Determinar conjunto de boas soluções.
  - Achar melhor solução para uma aplicação específica.

## Problemas Multiobjetivo (PMOs)

- Emprega-se AEs com o objetivo de usar diversidade para manter um **conjunto** de soluções, representando nichos de Aptidão (*fitness*) elevado.
- Desejável apresentar conjuntos distintos de possíveis soluções ao usuário, representando uma faixa de diferentes trocas (*trade-offs*) entre objetivos.

## PMOs: Abordagens Convencionais


- Uso de uma série de pesos dos valores da *função objetivo* para encontrar uma *função objetivo escalar única* que pode ser otimizada:

$$f'(x) = \sum_{i=1}^n w_i f_i(x)$$

- Para encontrar outras soluções é necessário re-otimizar com diferentes  $w_i$  (preferências do usuário não são estáticas).
- O processo acima é denominado ***scalarisation***

## PMOs: Curva de Pareto

- Estabelece o conjunto de soluções ótimas.
- Cada eixo cartesiano representa um objetivo a ser otimizado.




## PMOs com AE: Características

- Diferentes sub-populações buscam simultaneamente conjuntos de pontos nas proximidades da região de Pareto.
- Não é necessário buscar combinações de pesos ideais.
- Não é necessário que a curva (superfície) de Pareto seja adequada a métodos clássicos de otimização (contínua e diferenciável).



## PMOs com AE: Dominância

- Diz-se que  $x$  domina  $y$  se  $x$  é pelo menos **igual** aos maiores resultados em todos os critérios e **melhor** em pelo menos um critério.



## PMOs com AE: Vantagens

- População é dividida em subpopulações, cada uma contendo uma aptidão de acordo com a sua função objetivo (funções-objetivo diferentes para cada subpopulação).
  - Goldberg sugeriu o uso da aptidão baseada na dominância ao invés de funções objetivo.
- Modelo VEGA (*Vector-Evaluated Genetic Algorithm*) utiliza seleção de sobreviventes local, mas a seleção de pais e a recombinação são efetuados globalmente.
- O fato da natureza da busca ser baseada em populações possibilita que o processo de busca procure *simultaneamente* por conjuntos de pontos aproximando-se da frente de Pareto.

## PMOs com AE: Vantagens (cont.)

- Não é necessário efetuar “adivinhações” (*chutes*) para encontrar a combinação de pesos conveniente.
- Não efetua suposições a priori com respeito à forma da frente de Pareto – pode ser convexa, descontínua, ou qualquer outra forma.

## PMOs com AE: Requisitos

- Método para atribuição de aptidão.
  - Geralmente baseado na dominância.
- Preservação de conjuntos de pontos distintos
  - Análogo aos problemas multi-modais.
- Relembrar todos os pontos não-dominados que forem vistos
  - Geralmente utilizando elitismo ou um arquivo como memória.

## PMOs com AE: Atribuição de Aptidão

- Diferentes partes da população usam critérios (objetivos) distintos para otimizar.
  - ex. VEGA, mas sem garantia de diversidade.
- De acordo com a dominância.
  - Baseada em ordenação (*ranking*).
  - Aptidão relacionada com toda população.

## PMOs com AE: Preservar Diversidade

- Usualmente realizado por técnicas de nicho tais como:
  - Compartilhamento de aptidão.
  - Aumento da aptidão baseado no inverso da distância ao vizinho mais próximo.
  - Divisão do espaço de busca em regiões (caixas), contando os elementos lá contidos (ocupação).
- Todos contam com a mesma métrica de distância no espaço do genótipo/fenótipo.

## PMOs com AE: Pontos Importantes

- Podem usar algoritmos elitististas.
  - Ex. seleção de sobreviventes usando frentes.
- Geralmente os pontos não-dominados são mantidos em um arquivo.
  - Alguns algoritmos usam os pontos não-dominados como uma segunda população que pode ser utilizada pelos operadores.
  - Outros algoritmos também dividem os arquivos em regiões (ex. Pareto Archived Evolutionary Strategy – *PAES*).

## Exemplo de PMO

- Parei aqui
- Em um PMO Dinâmico (PMOD), espera-se que a região de Pareto mude com o tempo;
- Farina e colegas [Farina, 2004] propõem uma metodologia, baseada em AEs, para tratar problemas PMOD;
- Em PMOD, tenta-se chegar o mais próximo possível da região de Pareto.



## Resumo

- Alguns mecanismos presentes na evolução biológica permitem simultâneas explorações de um número de diferentes nichos ambientais;
- Problemas multimodais podem levar todos os indivíduos da população a um ótimo local;
- Sub-populações, em diferentes locais da superfície de busca, podem procurar simultaneamente vários ótimos;
- Os problemas multiobjetivos (conflitantes) são multimodais, o que torna o uso de AEs atrativo;
- Os AEs aplicados aos PMOs podem usar subpopulações para buscarem a região de Pareto com mais eficácia.

## Referências

- [Eiben, 2003] A. E. Eiben, J. E. Smith (2003). *Introduction to Evolutionary Computing*. Springer.
- [Farina, 2004] M. Farina, K. Deb, P. Amato (2004). “Dynamic optimization problems: test case, approximations, and applications”. *IEEE Trans. On Evolutionary Computation*. 8(5), October, pp. 425-442.